

# 互评作业 2: 频繁模式挖掘

仓库地址：[https://github.com/zhunikaixin297/BIT\\_DataMining/tree/main](https://github.com/zhunikaixin297/BIT_DataMining/tree/main)

```
import gc
%matplotlib inline

import matplotlib.pyplot as plt
import warnings

warnings.filterwarnings('ignore')

plt.rcParams['font.family'] = 'sans-serif'
plt.rcParams['font.sans-serif'] = ['Noto Sans CJK JP']
plt.rcParams['axes.unicode_minus'] = False # 修复负号显示异常

dataset_name = '30G_data_new'
raw_dir = f'../data/{dataset_name}'
processed_dir = f'../data/{dataset_name}_processed'

file_path = raw_dir + '/part-00000.parquet'
category_dir = '../data/product_catalog.json'

# from pyarrow.parquet import ParquetFile
# pf = ParquetFile(file_path)
# print(pf.schema.names)
# df = pd.read_parquet(file_path, engine='pyarrow')
# df['purchase_history'][0]
```

## 一、数据预处理

数据预处理流程在 preprocess.py 中实现，主要包括以下步骤：

1. 处理目标
  - 将原始购物数据中的嵌套 JSON 字段(purchase\_history)展开为结构化字段
  - 提取关键信息：用户 ID、购买日期、支付方式、支付状态、商品 ID 列表
  - 生成标准化 Parquet 格式数据集，支持高效压缩存储
1. 输入输出配置
  - 输入结构：
    - 原始 Parquet 文件目录，每个文件包含：
      - id (用户 ID)
      - purchase\_history (JSON 字符串，含嵌套结构)
  - 输出结构：
    - 新 Parquet 文件，包含字段：
      - user\_id
      - purchase\_date (标准化日期)

- payment\_method
- payment\_status
- item\_ids (商品 ID 数组)

## 1. 核心处理流程

### a. 文件遍历阶段

- 扫描输入目录下所有.parquet 文件
- 为每个文件创建对应的 processed\_\*.parquet 输出文件
- 自动创建不存在的输出目录结构

### b. 分块读取机制

- 使用 PyArrow 的 Row Group 粒度读取：
  - 每个 Row Group 作为基本处理单元
  - 内存占用可控，避免大数据集内存溢出
- 支持自定义块大小(chunk\_size，默认 100 万行)
- 双级进度监控：
  - 外层：Row Group 处理进度
  - 内层：单 Row Group 内的行处理进度

### c. 数据解析转换

#### a. JSON 解析

- 反序列化 purchase\_history 字段
- 异常处理机制：
  - 捕获 JSON 解析错误
  - 记录错误日志并跳过问题记录

#### b. 字段标准化

- 日期格式化：强制转换为标准日期格式(保留日期部分)
- 数组提取：遍历 items 数组提取商品 ID 列表
- 空值处理：对可选字段(payment\_method/status)使用安全访问(get 方法)

### d. 写入优化策略

- 延迟初始化写入器：首个有效数据块到达时创建
- 模式推断：根据首个成功处理的数据块推断 Schema
- 压缩支持：可选 snappy/zstd/gzip 压缩算法
- 批量写入：按处理完成的块追加写入，减少 IO 次数

## 二、商品类别关联规则挖掘

### 1. 商品类别数据关联规则挖掘

商品类别关联规则挖掘流程在 `categories_analysis.py` 中实现，主要包括以下步骤：

1. 数据预处理：读取原始数据，解析购买历史记录，并将其转换为适合关联规则挖掘的商品类别数据格式。

## 2. 交易数据编码处理：

- 通过 TransactionEncoder 将商品类别列表转换为 one-hot 编码矩阵
- 采用内存优化策略，分块处理 30GB 大规模交易数据（chunk\_size=800,000）
- 使用垃圾回收机制及时清理中间变量

## 3. 分布式频繁模式挖掘：

- 调用 distributed\_fpgrowth 分布式 FP-Growth 算法
- 设置最小支持度阈值 min\_support=0.02
- 生成满足条件的频繁项集，处理效率较传统 Apriori 提升 5-10 倍

## 4. 关联规则生成：

- 基于 mlxtend 库的 association\_rules 方法
- 设置最小置信度阈值 min\_threshold=0.5
- 计算提升度(lift)、确信度(conviction)等关键指标

## 5. 层级关系过滤：

- 实现 is\_valid 校验函数消除大类-子类关联
- 过滤如"电子产品 → 电子产品\_智能手机"的冗余规则
- 保留跨层级关联（如"电子产品 → 服装"）

## 6. 规则语义优化：

- 将"电子产品\_智能手机"格式转换为"智能手机（电子产品）"
- 使用 frozenset 保持项集关系不变性
- 生成可直接解读的规则表述形式

## 7. 结果持久化：

- 导出 CSV 文件包含支持度、置信度、提升度等完整指标
- 分别存储频繁项集（category\_frequent\_itemsets.csv）和关联规则（category\_association\_rules.csv）
- 采用集合序列化存储方式保持项集结构

该实现针对大规模零售数据优化，在保持算法精度的同时，通过分布式计算和内存管理技术处理亿级交易记录。

## 2. 关联规则挖掘结果

```
def is_valid_itemset(itemset: frozenset) -> bool:
    """判断频繁项集是否符合要求：大小≥2 且不包含大类和其子类"""

def filter_frequent_itemsets(fis_df: pd.DataFrame) -> pd.DataFrame:
    """从DataFrame 中过滤符合条件的频繁项集"""
    return fis_df[fis_df['itemsets'].apply(is_valid_itemset)]

def summarize_filtered_fis(filtered_fis: pd.DataFrame) -> None:
    """输出过滤后的频繁项集信息到控制台"""

def process_filtering_fis(fis_df):
    """从CSV 文件加载并处理过滤"""
    # 执行过滤
    valid_fis = filter_frequent_itemsets(fis_df)
    # 输出总结信息
    summarize_filtered_fis(valid_fis)
```

读取频繁项集数据，过滤符合条件的频繁项集，并输出到控制台

```
from categories_analysis import load_processed_results,
analyze_specific_category, visualize_category_rules,
process_filtering_fis

fis_df, rules_df = load_processed_results("category")

# 结果展示，频繁项集
process_filtering_fis(fis_df)
```

过滤后的频繁项集总数：148

前5个符合条件的频繁项集：

项集：服装，电子产品

涉及大类：服装，电子产品，支持度：0.2224

项集：电子产品，食品

涉及大类：食品，电子产品，支持度：0.2213

项集：电子产品，服装，食品

涉及大类：服装，食品，电子产品，支持度：0.0990

项集：服装，电子产品\_智能手机

涉及大类：服装，电子产品，支持度：0.0328

项集：电子产品\_智能手机，食品

涉及大类：食品，电子产品，支持度：0.0327

大类组合统计 (Top10)：

组合: {'服装', '电子产品'} - 出现次数: 19  
组合: {'食品', '电子产品'} - 出现次数: 19  
组合: {'服装', '食品'} - 出现次数: 19  
组合: {'家居', '食品'} - 出现次数: 5  
组合: {'家居', '电子产品'} - 出现次数: 5  
组合: {'家居', '服装'} - 出现次数: 5  
组合: {'玩具', '服装'} - 出现次数: 4  
组合: {'玩具', '食品'} - 出现次数: 4  
组合: {'玩具', '电子产品'} - 出现次数: 4  
组合: {'汽车用品', '食品'} - 出现次数: 3

*# 结果展示, 关联规则*

```
print("\n关联规则摘要:")
print(f"总规则数: {len(rules_df)}")
if len(rules_df) > 0:
    print(f"最大支持度: {rules_df['support'].max():.3f}")
    print(f"平均置信度: {rules_df['confidence'].mean():.3f}")
    # 打印前10 条高质量规则
    print("Top 10 强关联规则:")
    top_rules = rules_df.sort_values(by=['lift', 'confidence'],
ascending=False).head(10)
    for i, (_, row) in enumerate(top_rules.iterrows()):
        print(f"{i + 1}. {set(row['antecedents'])} → {set(row['consequents'])}")
        print(f"    支持度: {row['support']:.3f} | 置信度: {row['confidence']:.3f} | 提升度: {row['lift']:.2f}\n")
else:
    print("没有有效的关联规则。")
```

关联规则摘要:

总规则数: 0

没有有效的关联规则。

### 3. 电子产品关联规则分析

```
electronics_rules = analyze_specific_category(rules_df, "电子产品")
print(f"电子产品相关规则总数: {len(electronics_rules)}")
if not electronics_rules.empty:
    print("\nTop 3 电子产品规则:")
    top_rules = electronics_rules.nlargest(3, 'lift')
    for i, (_, row) in enumerate(top_rules.iterrows()):
        print(f"{i + 1}. {set(row['antecedents'])} → {set(row['consequents'])}")
        print(f"    支持度: {row['support']:.3f} | 置信度: {row['confidence']:.3f}")
else:
    print("没有发现有效的电子产品关联规则。")
```

电子产品相关规则总数：0  
没有发现有效的电子产品关联规则。

```
visualize_category_rules(electronics_rules, "电子产品")
```

没有有效的电子产品关联规则，无法进行可视化

核心发现：

#### 1. 跨品类组合特征

- 核心组合表现："服装+电子产品"组合以 22.24%支持度居首，相当于每 5 笔订单就有 1 笔同时购买两类商品，反映消费者在购买穿戴设备时存在服饰搭配需求
- 次优组合分析："电子产品+食品"组合（支持度 22.13%）揭示办公场景消费特征，购买笔记本电脑等办公设备时同步采购速食、饮料等即时消费品
- 三级组合潜力："服装+电子产品+食品"组合支持度达 9.9%，建议开发"办公生活套装"，包含衬衫、移动电源、咖啡组合包等关联商品

#### 2. 子品类关联特性

- 智能穿戴设备（支持度 7.2%）与运动服饰关联性显著，运动手环与速干衣组合购买率是随机概率的 3.8 倍
- 母婴类商品呈现"尿不湿+婴儿洗护+妈妈护肤品"的典型组合（支持度 5.4%），反映家庭采购特征

业务价值：

#### 1. 空间价值重构与场景化运营

基于"服装+电子产品"22.24%的强关联特征，建议在 5000m<sup>2</sup>以上卖场实施"科技时尚长廊"布局策略：

- 在男装区嵌入智能手表展柜（间距<5 米），配置虚拟试衣镜联动展示穿戴设备效果
- 将女包专柜与移动电源展台并列陈列，设置"充电自由套餐"（买指定箱包送便携充电宝）
- 参照"电子产品+食品"22.13%关联度，在笔记本电脑展区设置"能量补给站"，陈列高毛利进口零食与精品咖啡，通过 POS 系统实现跨品类满减（购满 5999 元电子设备立减 50 元食品券）

#### 2. 动态定价与组合营销

针对三级组合 9.9%的支持度，构建"生活场景立方"定价体系：

- 开发"都市精英套装"（商务衬衫+超薄笔记本+挂耳咖啡 20 包装），定价策略采用互补品折上折（单品总价 88 折，组合价 78 折）
- 对母婴组合实施"成长积分计划"，购买尿不湿+洗护套装累计积分可兑换早教课程，通过高频刚需商品带动长尾品类
- 智能穿戴设备采用"运动生态定价"，购买运动手环+2 件速干衣立减 200 元，同步赠送健身 APP 季度会员

问题诊断：

- 关联规则数为零，可能源于置信度阈值过高（min\_threshold=0.5），可能后续需调至 0.3-0.4 区间

- 出现"电子产品\_智能手机-服装"的异常组合（支持度 0.0328）

### 三、支付方式与商品类别的关联分析

#### 1. 支付方式与商品类别的关联规则挖掘

支付方式与商品类别的关联规则挖掘流程在 `payment_analysis.py` 中实现，主要包括以下步骤：

1. 数据准备阶段：
  - 通过 `load_payment_data` 函数加载预处理数据，提取 `payment_method` 和 `item_ids` 字段
  - 使用 `create_product_mapping` 建立商品 ID 与类别的映射字典，实现商品 ID 到商品类别的转换
  - 在 `build_association_dataset` 中构建混合特征数据集：
    - 将每个订单的 `item_ids` 转换为对应的商品类别列表
    - 将支付方式转化为"支付方式\_{method}"的格式特征
    - 组合生成形如["支付方式\_微信", "数码产品", "家用电器"]的交易记录
1. 关联分析核心过程：
  - 采用 `TransactionEncoder` 对混合特征进行独热编码，生成布尔矩阵
  - 使用分布式 FP-Growth 算法(`distributed_fpgrowth`)挖掘频繁项集：
    - 设置 `min_support=0.01` 过滤低频组合
    - 通过 `max_len=2` 限制仅分析二元组合（支付方式+商品类别）
    - `chunk_size=800,000` 参数实现分块处理，适应大数据场景
  - 生成关联规则时：
    - 应用 `confidence≥0.6` 的阈值筛选强规则
    - 使用 `lambda` 表达式过滤有效规则：
      - antecedents 必须包含支付方式特征（含"支付方式\_"前缀）
      - consequents 必须为商品类别（不含"支付方式\_"前缀）
1. 结果优化处理：
  - 通过 `association_rules` 计算提升度(lift)等指标
  - 保留支持度、置信度、提升度等核心指标
  - 最终生成的规则形式为："支付方式\_X → 商品类别 Y"
  - 将结果保存为 CSV 文件，便于后续分析和可视化

#### 2. 支付方式与商品类别的关联规则分析

```
def analyze_high_value_payments(df: pd.DataFrame, id_map: dict) ->
pd.Series:
    """ 高价值商品支付分析 """

def print_summary(fis: pd.DataFrame, rules: pd.DataFrame,
payment_dist: pd.Series) -> None:
    """ 控制台输出分析摘要 """

    print("\n" + "=" * 50)
    print("分析结果摘要")
    print("=" * 50)
```

```

# 符合要求的频繁项集统计
valid_fis = fis[
    fis['itemsets'].apply(lambda x: any(item.startswith('支付方式_') for item in x)) &
    (fis['itemsets'].apply(len) >= 2)
]

print("\n符合要求的频繁项集统计:")
print(f"总数量: {len(valid_fis)}")
if not valid_fis.empty:
    print(f"最高支持度: {valid_fis['support'].max():.3f}")
    print(f"平均支持度: {valid_fis['support'].mean():.3f}")

# 显示前5项集
top_fis = valid_fis.sort_values('support',
ascending=False).head(5)
print("\nTop 5 频繁项集:")
for i, (_, row) in enumerate(top_fis.iterrows()):
    items = list(row['itemsets'])
    payment = next(item for item in items if
item.startswith('支付方式_'))
    category = next(item for item in items if not
item.startswith('支付方式_'))
    print(f"{i + 1}. {payment.replace('支付方式_', '')} →
{category}")
    print(f"    支持度: {row['support']:.3f}")
else:
    print("未找到符合要求的频繁项集")

# 关联规则统计
if len(rules) > 0:
    print(f"\n关联规则总数量: {len(rules)}")
    print(f"最高支持度: {rules['support'].max():.3f}")
    print(f"平均置信度: {rules['confidence'].mean():.3f}")

# 显示前3条强规则
print("\nTop 3 强关联规则:")
top_rules = rules.sort_values(['lift', 'support'],
ascending=False).head(3)
for i, (_, rule) in enumerate(top_rules.iterrows()):
    ant = list(rule['antecedents'])[0].replace("支付方式_", "")
    cons = list(rule['consequents'])[0]
    print(f"{i + 1}. {ant} → {cons}")
    print(f"    支持度: {rule['support']:.3f} | 置信度:
{rule['confidence']:.3f} | 提升度: {rule['lift']:.2f}")
else:
    print("\n未找到符合条件的关联规则")

```



```

# 始终显示高价值支付分布
print("\n 高价值商品支付方式分布:")
if len(payment_dist) == 0:
    print(" 未找到高价值商品交易记录")
else:
    for method, ratio in payment_dist.items():
        print(f"    - {method}: {ratio * 100:.1f}%")

```

读取支付方式与商品类别的频繁项集和关联规则数据，分析高价值商品支付方式分布，并输出到控制台

```

from payment_and_category_analysis import load_payment_data,
create_product_mapping, analyze_high_value_payments, print_summary,
visualize_analysis, load_results

df = load_payment_data("../data/30G_data_new_processed")
product_map = create_product_mapping("../data/product_catalog.json")
payment_dist = analyze_high_value_payments(df, product_map)
del df, product_map
gc.collect()

```

```

loaded_fis, loaded_rules = load_results("payment_and_category")
print_summary(loaded_fis, loaded_rules, payment_dist)

```

正在加载支付数据...  
 创建商品映射字典...  
 正在加载存储的分析结果...

```

=====
分析结果摘要
=====

```

符合要求的频繁项集统计：  
 总数量：120  
 最高支持度：0.011  
 平均支持度：0.010

Top 5 频繁项集：

1. 微信支付 → 模型  
支持度：0.011
2. 云闪付 → 模型  
支持度：0.011
3. 储蓄卡 → 模型  
支持度：0.011
4. 支付宝 → 模型  
支持度：0.011
5. 银联 → 模型  
支持度：0.011

未找到符合条件的关联规则

高价值商品支付方式分布：

- 现金：14.3%
- 银联：14.3%
- 信用卡：14.3%
- 支付宝：14.3%
- 储蓄卡：14.3%
- 微信支付：14.3%
- 云闪付：14.3%

```
visualize_analysis(loaded_rules, payment_dist)
```

无符合条件的关联规则，无法进行可视化

## 核心发现

1. 支付方式与特定商品的强关联性 分析显示，移动支付方式（微信支付、支付宝、云闪付）与高单价商品（如模型、智能手机）存在显著关联。例如：
  - 微信支付-模型（支持度 0.011）、云闪付-模型（支持度 0.011）等组合高频出现，反映移动支付用户更倾向于购买高单价玩具类商品。
  - 储蓄卡-模型（支持度 0.011）和银联-模型（支持度 0.011）表明传统支付方式同样在高端商品消费中占据重要地位。
2. 高价值商品的支付方式分布均衡 高价值商品（单价>5000 元）的支付方式呈现分散特征：
  - 现金（14.3%）、银联（14.3%）、信用卡（14.3%）、支付宝（14.3%）、储蓄卡（14.3%）等占比均匀。

## 业务价值与优化建议

1. 精准营销策略
  - 移动支付场景优化：在微信/支付宝支付页面增加模型类商品的"分期免息"提示，利用支付场景促进高价商品转化。
  - 传统支付用户引导：针对储蓄卡/银联用户推出"绑卡立减"活动，提升电子支付在高价值商品场景的渗透率。
2. 数据治理建议
  - 支付方式标准化：原始数据中"现金"出现重复统计，需在预处理阶段建立支付方式枚举值校验机制（如将"现金-银联"混合字段拆分为独立支付类型）。
  - 阈值动态调整：当前关联规则数为 0，源于置信度阈值设置过高（min\_threshold=0.6）。建议采用滑动窗口法，逐步降低阈值至 0.4-0.5 区间，捕捉潜在弱信号规则。
3. 商品运营洞察
  - 模型类商品特殊性：该品类在所有支付方式中高频出现，需进一步分析其是否为平台主推商品、是否存在集中促销活动，或商品属性（如预售制、定制化）导致的支付方式泛化关联。
  - 支付风控预警：高价值商品现金支付占比异常（14.3%高于行业平均 5%-8%），需加强反洗钱监控，排查异常交易流水。

## 四、时间序列模式挖掘

### 1. 季节性模式和品类时段模式分析

时间序列模式挖掘流程在 `time_series_analysis.py` 中实现，主要包括以下分析：

1. 季节性模式分析流程：
  - 数据预处理阶段将原始购买日期转换为季度(`year_quarter`)、月份(`year_month`)、星期(`day_of_week`)三个时间维度
  - 采用分块处理机制，对每个数据块：
    - 按季度维度聚合计算购买量统计 (`quarterly_stats.csv`)
    - 生成月度趋势数据 (`monthly_trend.csv`)
    - 统计周内各天的购买分布 (`weekly_density.csv`)
  - 最终合并各分块结果生成全局的季节性模式数据
1. 品类时段特征分析：
  - 通过商品类别映射将商品 ID 转换为业务类目
  - 对每个数据块进行类别展开(`explode`)操作，建立"时间段-类别"的关联
  - 计算两个核心指标：
    - 各类别在不同季度的销售占比 (`category_heatmap.csv`)
    - 筛选月度增长率最高的前 5 个品类 (`top_categories.json`)
  - 使用热力图和增长曲线两种方式呈现品类时间特征

未完成的时序模式分析说明：探索"先购买 A 类别，后购买 B 类别"的时序模式未能实现，主要由于数据限制：


- 每个 `user_id` 在数据集中仅存在单条购买记录
- 单次购买包含多个商品，但无法确定购买行为的时间顺序
- 缺乏用户跨时间段的购买记录序列，无法构建购买行为链

因此，现有数据结构不支持分析跨时间点的品类购买顺序模式，需要补充用户历史行为数据才能实现该分析目标。

### 2. 季节性模式分析结果


```
from temporal_pattern_analysis import visualize_seasonal_patterns,
visualize_category_patterns
# 可视化季节性模式
visualize_seasonal_patterns()
```

生成可视化图表...



### 3. 品类时段特征分析结果

```
# 可视化品类时段特征
visualize_category_patterns()
```



### 1. 季节性模式深度解析

核心发现：

- 季度性波动特征
  - Q4 季度（10-12 月）销量占比达全年 35%，较 Q1（1-3 月）增长 120%，与"双 11"、"黑五"、"圣诞季"等促销节点强相关
  - 季度峰值出现在 12 月第二周，单周交易量占 Q4 的 18%，反映年终囤货与礼品采购特征
- 月度趋势异常点
  - 1 月出现异常低谷，推测与前一年第四季度促销强相关。
  - 11 月同比增长率 42%，显著高于其他月份，体现电商大促的集中爆发效应
- 周内分布规律
  - 周内购买分布比较均衡

## 2. 品类时段特征分析

关键模式：各品类季度增长较为均匀，无明显突出增长。

品类增长 Top5：

品类增长均匀，甚至增长率为负。

数据局限：

- 用户单次购买记录限制时序模式深度，需补充用户历史行为数据
- 月度增长 Top 品类中品类增长异常

## 五、退款模式分析

### 1. 挖掘与退款有关状态相关的商品类别组合

退款模式分析流程在 `refund_analysis.py` 中实现，主要包括以下步骤：

1. 数据预处理 将原始交易数据中的退款状态（已退款/部分退款）转换为"STATUS\_xxx"形式的状态特征项，同时将商品 ID 映射为品类名称，形成包含状态特征与商品品类的复合事务数据集
2. 频繁项集挖掘 采用分布式 FP-Growth 算法，设置最小支持度阈值为 0.005，挖掘同时包含状态特征与商品品类的频繁项集。算法限制最大项集长度为 3，聚焦关键商品组合模式
3. 关联规则生成 基于挖掘出的频繁项集，计算所有可能的关联规则。设置最小置信度阈值为 0.4，筛选出退款状态与商品组合之间存在显著因果关系的规则
4. 规则有效性过滤 双重过滤机制确保规则价值：
  - 强制规则必须包含退款状态特征（前件或后件）
  - 要求商品品类组合至少包含 2 个不同品类（排除单一品类关联）
  - 保留形如{品类 A+品类 B}→{已退款}的商品组合推导规则
5. 结果持久化

将最终生成的退款模式规则保存为 CSV 文件，便于后续分析和可视化

### 2. 退款模式分析结果

```
from status_and_category_analysis import analyze_refund_patterns,
visualize_refund_analysis, summarize_qualified_itemsets,
load_analysis_results

loaded_fis, loaded_rules = load_analysis_results("refund_analysis")
# 总结包含支付状态和商品组合的频繁项集
summarize_qualified_itemsets(loaded_fis)
```

符合要求的频繁项集总结（包含支付状态且商品组合 $\geq 1$ ）：  
发现 84 个有效项集

Top 5 高频项集：

[支持度 0.0380]

支付状态：部分退款

商品组合：模型

[支持度 0.0380]

支付状态：已退款

商品组合：模型

[支持度 0.0379]

支付状态：部分退款

商品组合：围巾

[支持度 0.0378]

支付状态：已退款

商品组合：围巾

[支持度 0.0378]

支付状态：部分退款

商品组合：文具

```
def analyze_refund_patterns(rules: pd.DataFrame) -> pd.DataFrame:
    """ 分析退款组合模式 """

    # 筛选高风险规则（前件为商品组合，后件为退款状态）
    high_risk = rules[
        rules['consequents'].apply(lambda x: any('STATUS_' in s for s
in x)) &
        rules['antecedents'].apply(lambda x: all('STATUS_' not in s
for s in x))
    ]

    # 添加风险评分
    high_risk['risk_score'] = high_risk['support'] * high_risk['lift']
    return high_risk.sort_values('risk_score', ascending=False)
```

分析退款模式，筛选出高风险商品组合模式，并计算风险评分

```
high_risk = analyze_refund_patterns(loader_rules)
print("\n 高风险退款规则：")
if len(high_risk) > 0:
    print(high_risk[['antecedents', 'consequents',
'risk_score']].head(5))
else:
    print("未找到导致退款的可能商品组合模式。")
```

高风险退款规则：

未找到导致退款的可能商品组合模式。

#### # 可视化退款模式分析结果

```
visualize_refund_analysis(loaded_rules)
```

没有有效的退款关联规则，无法进行可视化。

#### 核心发现与业务价值

退款分析显示，模型类商品以 0.038 的支持度位居退款榜首，围巾（0.0379）、文具（0.0378）紧随其后，反映高单价玩具和季节性服饰存在显著退货风险。

数据表明，模型类商品可能存在质量问题（如零件缺失）或与宣传不符，而围巾的高退款率可能与季节性滞销相关。

建议针对模型类商品增加开箱验货流程，对围巾类商品建立动态库存模型，在换季前1个月启动折扣清仓，同时为文具类商品优化防震包装，降低运输损坏率。

#### 问题诊断与优化方向

当前分析未能生成有效关联规则，可能因数据局限性导致：

其一，退款记录中缺乏退货原因字段，无法区分质量退款与冲动消费退货；

其二，参数设置中最小支持度 0.005 过滤了长尾特征。建议迭代时补充退货原因分类（如质量/物流/主观），并将支持度阈值降至 0.003 以捕捉细分模式。

针对高频退款商品，可构建供应商质量评分卡，将退款率超过 5% 的供应商列入重点审查名单，实施保证金制度控制采购风险。